

待标注数据集说明（专家下发版）

本文件夹为金标准标注专家咨询流程的下发包。数据**已全部脱敏**。

阅读顺序：01_专家咨询问卷 → 02_标注手册 → 03_标注表说明与列定义 → 本文件 → 05_数据回收登记表。

一、流程总览（五步）

步骤	材料	负责人	说明
① 资质登记	01_专家咨询问卷·第一、三部分	专家	科室/职称/报告阅读经验；同步登记署名意向
② 培训试标	dataset/01-第一轮2人盲标/数据集 + 02_标注手册	专家	每域试标 20 份，核对口径
③ 正式标注	dataset/01-第一轮2人盲标/待标注 CSV（与《金标准标注工作簿》同构，含 A1_/A2_/flag/note/arbitration 空列）	标注员 A1/A2	依据《标注手册》双人独立盲法 全量标注 （1,470 份/人，不抽样、不分摊），各自只填 A1_/A2_ 列
④ 回收核验与仲裁	05_数据回收登记表.xlsx（recycle/01-第一轮2人盲标结果/）；仲裁裁定工作簿.xlsx（dataset/02-仲裁裁定/）；回收件存入 recycle/	课题组/仲裁员	按"完整性核验清单"逐项勾选；仲裁员对 A1≠A2 分歧个案仲裁， 仲裁意见用于修订标注手册（v1.0→v2.0）
⑤ 重复标注	02_标注手册（现行 v2.0）	标注员 A1/A2	间隔≥3 天完成重复标注（自重复 10% 及重标任务，组内一致性 κ 用）

二、数据集清单（共 1,470 份）

文件	域	份数	列结构	对应工作簿 sheet
dataset/01-第一轮2人盲标/ECG_H_待标注.csv	① H社区心电图结论	570	sample_id, year, pseudo_id, text + A1_/A2_ 各 12变量 + flag/note/arbitration（31列）	ECG_H
dataset/01-第一轮2人盲标/ECHO_PG_待标注.csv	② PG心脏超声报告	300	sample_id, exam_date, pseudo_id, text + A1_/A2_ 各9变量 + flag/note/arbitration（25列）	ECHO_PG
dataset/01-第一轮2人盲标/ABDUS_PG_待标注.csv	③ PG腹部超声	300	sample_id, exam_date, pseudo_id, text + A1_/A2_ 各7变量 + flag/note/arbitration（21列）	ABDUS_PG

文件	域	份数	列结构	对应工作簿 sheet
dataset/01-第一轮2人盲标/ABDUS_H_待标注.csv	④ H社区腹部超声	300	sample_id, year, pseudo_id, text + A1_/A2_ 各7变量 + flag/note/arbitration (21列)	ABDUS_H

- **表结构说明**：待标注 CSV源信息列 + 原文 + A1_/A2_ 双标注列 + flag/note/arbitration，下发时标注列与仲裁列均为空，专家直接在 CSV 中填写；
- **sample_id**：域前缀 + 四位序号（如 ECG_0001），与工作簿行一一对应，标注时勿改动；
- **text**：待标注原文。ECG 域为结论文本（截断至 150 字符）；腹超域为"超声所见 + 主检结果"拼接文本（截断至 600 字符）；echo 域为检查所见全文；
- **year / exam_date**：检查年份/日期，仅用于后续分年份一致性统计，标注时不参与判定；
- **抽样设计**：固定随机种子（seed=42）可复现——先抽出 600 份母体（ECG 域按年份分层每年 60 + 房颤/传导阻滞/ST-T 特殊层各 50，同人同年去重后 570 份即全量；echo 域按规则预分类 abnormal 304/normal 149/normal_variant 147；腹超 PG 域规则阳性 306/阴性 294；腹超 H 域每年 50 + 阳性补足至 600），再由 code/05_downsample_gold_300.py 从母体嵌套抽出双标子集 300/域（echo 150/75/75；腹超 PG 阳性/阴性各 150；腹超 H 每年 30 + 阳性补足 90）。样本量依据：Flack 1988/Bujang & Baharum 2017（ $\alpha=0.05$ 、power=80%、 $\kappa\approx 0.80$ 时 CI 半宽 $\approx \pm 0.06$ ，且支撑 7 层年份分层曲线）。

三、标注任务速查

域	输出变量	填写约定	手册章节
① ECG	ecg_normal / ecg_af / ecg_pac_pvc / ecg_stt / ecg_avblock / ecg_bbb / ecg_rate / ecg_srirr / ecg_axis / ecg_qwave_mi / ecg_other / ecg_unreadable	多标签，二值 0/1	02_标注手册·域①
② echo	echo_normal / echo_variant / echo_lvh / echo_la_dilate / ef_value（数值）/ ef_abnormal / reflux_grade（none/trace_mild/moderate/severe）/ echo_rhythm / echo_unreadable	二值列 0/1；分级列按枚举；ef_value 抄原文数字，无则空	02_标注手册·域②
③④ 腹超	us_fatty / us_fatty_degree（轻/中/重或空）/ us_hepatic_other / us_gallstone / us_kidney_cyst / us_unreadable / main_discrepant	二值列 0/1；分度仅原文出现才标	02_标注手册·域③

通用约定（详见《03_标注表说明与列定义.md》）：**否定优先**（先判"未见/无明显/无"再判阳性）；规则未覆盖 → flag=1 + note 一句话；二值列仅填 0/1，不适用留空。

四、回收要求

1. 填写对象为下发的待标注 CSV：标注员只填本人 A1_/A2_ 列及 flag/note；**arbitration 列留空**（仅仲裁员对 A1≠A2 分歧个案填写）；
2. 不得增删行、修改 sample_id 或 text；

3. 回收时由课题组在《05_数据回收登记表.xlsx》登记批次并执行八项完整性核验，结论"合格"方可进入一致性统计（任务包根目录运行 `code/04_agreement_stats.py`）。

五、验收门槛（供专家知悉）

- 标注员间 Cohen's $\kappa \geq 0.80$ ；各自 vs 仲裁后终版 $F1 \geq 0.90$ ；准确率 $\geq 95\%$ ；分年份层内准确率 $\geq 90\%$ ；
- 组内自重复 $\kappa \geq 0.85$ ；
- 未达标层：修订手册/规则后仅重标对应层；对应抽取器不得冻结入主分析。